



一道题的两个世界 — sllama0164「锡克教有几位祖师?」(参考答案:十)
同一段音频、同一台 H100,全部为实测毫秒



- ① 世界 A(探针关,never 臂实测):小模型不会这道题,但它没有说"不知道",而是绕——487 字符,先断言"只有一位 Guru",再展开一段辨析("However... to avoid confusion..."),解码整整 3.10 秒,判分:错。
- ② 世界 B(探针开,conservative 臂实测):同一段音频流入时,探针逐块的运行分数已经在高位(0.71/0.67/0.66);话音一落,21 毫秒读出 eot=0.631 ≥ 阈值 0.513 → 升级。注意:此刻本地回答一个字都还没生成——探针读的是内部状态,不是回答文本。
- ③ 升级路径:stall 话术(21 ms)掩护下,gpt-5.5 用 1.68 秒给出"十位人间祖师",talker 用 0.62 秒转述——总计 2.32 秒。比世界 A 快 0.78 秒,并且从错变对。这不是特例:cons 档送走的 38 题里,这样"又快又对"的结构反复出现(它们的本地 P50 高达 2.38 秒)。
- ④ 拐弯就是把中间那根红条从本地队列里抽走:全池本地 P50 本来 1.50 秒;38 道慢题(P50 2.38 秒)离开后,留下 212 题的 P50 掉到 0.94 秒。38 题走专家路径(约 3 秒)但只占 15% 的质量,压不过 85% 变快的本地质量——于是整臂中位 1.52 → 1.17 秒,左折出现。
- ⑤ 边界(8ab Addendum 4 的修正):探针挑的是"会错",不是"会绕"——它对不绕的自信错抓得一样准(81% vs 81%)。拐弯只在"会错的题恰好也慢"的池子出现(sllama/striviaqa 的 hedging、sreason 的长推理链);sdqa 错得又快又干脆,就没有拐弯。