



frozen 池:重建曲线 + 我们自己的噪声带



18 个 live 差值全部跨过 0 线



- ① 左图蓝线不是新实验,是把已经测过的结果【重新混合】画出的连续曲线。为什么可以这么做:三个档位的升级集合完全嵌套、探针分数逐位相同,所以"升级率 = r 时会发生什么"对每道题都有现成的实测答案,\$0 成本。
- ② 蓝色阴影带 = 我们自己的复现噪声(95% 区间)。它的来源实测过:同一道题、同一段音频、两次都留在本地,判分结果有 2.3%~18.8% 的概率翻转(专家采样 + 判分器波动)。换算下来,一个臂的准确率天生有 $\pm .02 \sim .03$ 的抖动。
- ③ 红方块:旧探针(v2)在这个档的 .621。新探针(v3)测得 .596,当时我们写成"v3 退步了"——但它完全落在噪声带里,配对检验 $p = .44$ 。那个"退步"是我们对着噪声讲了故事,已在 88ad 正式撤回。
- ④ 绿星:阈值本该升 50% 却实际升了 61%(标定漂移)。把它修回 50%,准确率只动 $+.004$ ——所以这个 bug 伤的是【成本】(白白多花 11% 的专家调用),不是准确率。修正后的阈值已入库。
- ⑤ 右图:新旧探针在 6 个数据集 $\times$ 3 个档位的全部 18 个 live 对比,置信区间全部跨 0——【单次 live 实验分辨不了小于 3 分的差别】。v3 更好的证据在离线 AUC(统计上紧得多,.860 $\rightarrow$.879),不在这些曲线上。
- ⑥ 给读者的规矩(本图存在的意义):比较两个版本/两个策略,要用配对检验、AUC、同率 precision 这类低方差读数;臂准确率的小数点后第二位是噪声,谁拿它讲故事都不要信——包括我们自己(③就是案例)。