


slama 讲解版 — Llama Questions:会挑的路由,花一半的钱拿到全升级的分 (n=250,probe v3;全项目最强正面结果,含统计修正后的表述)



- ① 蓝色曲线 = 实时系统,同样 250 道题跑四遍,唯一区别是送给 gpt-5.5 的比例。这个池是英文短事实题,小模型底子好(不升级也有 .836),所以整条曲线都贴着天花板。
- ② 绿色虚线 = "无脑策略":每道题都送 gpt-5.5,得 .928。注意它花的专家调用是 @50% 档的【两倍】。直觉上它该是准确率上界——这张图的看点就是它不是。
- ③ @50% 的 .948 比全升级的 .928 高 .020——但诚实地说(\$8ad 配对检验):250 题里两种策略只在 7 题上结果不同(6 比 1), $p=.125$,“更高”不能单独下结论。能下的结论是:【至少打平,而专家调用省了一半】。
- ④ 为什么会这样(这部分是铁的):探针把 250 题干净地分成两半——它留在本地的 125 题,小模型自己 .976(专家也只有 .968,配对 $p=1.0$,打平);它送云的 125 题,小模型只有 .696,专家救到 .888($p<.0001$)。这个分割的强度 $z=6.5$ ——探针真的知道哪些题小模型会挂。
- ⑤ 所以正确的头条不是“小模型打败了 gpt-5.5”(那句在打平的 125 题上不成立),而是:【“全部送云”不是上界,会挑的路由用一半的成本拿到同样好(方向上更好)的结果】。对系统设计者:专家预算减半,零代价。
- ⑥ 此池官方没有公布 MiniCPM 数字,所以没有官方锚线;判分器是 OpenAudioBench 官方的(gpt-4o + 官方 prompt),对比公平。此池复现噪声全项目最低(同题重测翻转率 2.3%),④的分解在所有池里最可信。