


图5 讲解版 — Speech Web Questions:三种运行形态,什么能比、什么不能比
(n=250,probe v3;所有线同一把判分尺)



- ① 官方 70.2 是离线 chat 模式(turn-based:整段音频一次给模型、无对话人格、可写长答案)。它是【锚线】,用来对齐绝对水平——不能拿我们的曲线和它比大小,因为运行形态不同。
- ② 桥:同 250 条音频、切回离线模式、同一判分器,我们得 .716 $\approx$ 官方 .702(+.014 = 250 题子采样噪声)。这条线证明【官方数字我们复现得出来】,下面所有差距都不是“能力丢了”或“测错了”。
- ③ 唯一的“系统”数字:实时双工 loop 的四个臂(问题、同 loop、同尺,内部配对)。floor .568 比②低 .148 = 【loop 代价】:实时人格答案短(中位 820 vs 2186 字符)+ 512 token 截断 + 流式分块。曲线内部的上升(.568 $\rightarrow$.732)才是 gate 的因果贡献。
- ④ 对比模型也全是离线数字。当我们的【实时】@50% (.732) 接近它的【离线】.749 时,这个比较方向对我们是保守的——离线普遍高于实时,若 Qwen 被迫跑实时只会更低。反向比较(拿我们离线打别人离线)不做:对方无双工接口,完全对齐的实时对局不存在。
- ⑤ @50% 的 .732 回到官方线①之上:实时系统靠路由把 turn-based 让掉的分挣回来了。注意误差棒 $\pm .05$:复现噪声地板(\$8ad)是每臂 $\pm .02-.03$,小于 3 分的差别不要解读。
- ⑥ 严格的对比阶梯是四层:无 router(.568) < 随机升级@同预算 < 我们的 router(.732) < 全升级(.864)。本图只画了首尾两层:router 对随机的净超额(+.045/+0.035/+0.066)在正式图5(dualview)的灰虚线上——那才是“挑得准”的证据,这里的 +.164 是“机制+挑得准”的总和。