


图5 讲解版 — Speech Web Questions:三种运行形态,什么能比、什么不能比
(n=250,probe v3;所有线同一把判分尺)



- ① 官方 70.2 是离线 chat 模式(turn-based:整段音频一次给模型、无对话人格、可写长答案)。它是【锚线】,用来对齐绝对水平——不能拿我们的曲线和它比大小,因为运行形态不同。
- ② "官方同款测法"对照组:同样这 250 道题,我们也按官方的方式测了一遍(整段音频一次给模型、慢慢想、答案随便长),得 .716 $\approx$ 官方 .702。用途只有一个:证明官方分数我们测得出来——所以下面实时模式掉的分,是测法不同造成的,不是模型坏了或测错了。
- ③ 蓝色曲线 = 我们的真系统(实时对话:边听边准备、话音一落就答)。四个点是同样 250 道题跑四遍,唯一区别是送给 gpt-5.5 的比例(0/15/30/50%)。最左 0% 的点 = 不开 router 的实时模式,比②低 .148——这是"必须马上答、答案短、超长被截断"的实时形态成本;曲线右爬 = 开 router 挣回来的分。
- ④ 对比模型也全是离线数字。当我们的【实时】@50% (.732) 接近它的【离线】.749 时,这个比较方向对我们是保守的——离线普遍高于实时,若 Qwen 被迫跑实时只会更低。反向比较(拿我们离线打别人离线)不做:对方无双工接口,完全对齐的实时对局不存在。
- ⑤ @50% 的 .732 回到官方线①之上:实时系统靠路由把 turn-based 让掉的分挣回来了。注意误差棒 $\pm .05$:复现噪声地板(\$8ad)是每臂 $\pm .02-.03$,小于 3 分的差别不要解读。
- ⑥ 严格的对比阶梯是四层:无 router(.568) < 随机升级@同预算 < 我们的 router(.732) < 全升级(.864)。本图只画了首尾两层:router 对随机的净超额(+.045/+0.035/+0.066)在正式图5(dualview)的灰虚线上——那才是"挑得准"的证据,这里的 +.164 是"机制+挑得准"的总和。